

1. Descompunerea la Valori Singulare (SVD) via Matricea de Covarianță

Fie matricea urmelor de consum $A \in \mathbb{R}^{m \times n}$. Descompunerea SVD este definită ca:

$$A = U\Sigma V^T \quad (1)$$

Pentru implementare, se calculează matricea de covarianță $M = A^T A \in \mathbb{R}^{n \times n}$, care este simetrică și pozitiv semidefinită. Proprietatea esențială exploatată este:

$$M = A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^2 V^T \quad (2)$$

Deoarece matricea U este ortogonală ($U^T U = I$), valorile proprii ale matricei M (notate cu λ_i) reprezintă pătratele valorilor singulare ale matricei A :

$$\lambda_i = \sigma_i^2 \implies \sigma_i = \sqrt{\lambda_i} \quad (3)$$

Vectorii proprii ai matricei M corespund coloanelor matricei V (vectorii singulari drepecți).

2. Tridiagonalizarea (Reflexii Householder)

Matricea M este adusă la o formă tridiagonală T prin reflexii Householder. O matrice Householder este ortogonală și are forma:

$$H = I - 2uu^T \quad (4)$$

unde u este un vector coloană cu norma $\|u\|_2 = 1$.

Pentru a anula elementele de sub prima subdiagonală a coloanei k , se izolează vectorul $x = M[k+1 : n, k]$. Vectorul reflector se calculează astfel:

$$v = x + \text{sign}(x_1)\|x\|_2 e_1 \quad (5)$$

unde $e_1 = [1, 0, \dots, 0]^T$, după care se normalizează: $u = \frac{v}{\|v\|_2}$.

Prin transformări de similaritate succesive, obținem:

$$T = H_{n-2} \dots H_1 M H_1 \dots H_{n-2} \quad (6)$$

3. Diagonalizarea prin Iterația QR

Pe matricea tridiagonală T se aplică algoritmul iterativ QR. La fiecare pas k , matricea este descompusă ortogonal:

$$T^{(k)} = Q^{(k)} R^{(k)} \quad (7)$$

Matricea la pasul următor se formează prin inversarea factorilor:

$$T^{(k+1)} = R^{(k)} Q^{(k)} = (Q^{(k)})^T T^{(k)} Q^{(k)} \quad (8)$$

Algoritmul converge către o matrice diagonală D , ale cărei elemente sunt valorile proprii λ_i . Vectorii proprii se obțin prin înmulțirea acumulată a matricelor $Q^{(k)}$.

4. Calculul Vectorilor Singolari Stângi și Truncated SVD

Vectorii singolari stângi (coloanele matricei U) sunt calculați prin proiecția directă:

$$u_i = \frac{1}{\sigma_i} A v_i, \quad \text{pentru } \sigma_i > 0 \quad (9)$$

Conform Teoremei Eckart-Young-Mirsky, cea mai bună aproximare de rang k a matricei A se obține prin trunchierea sumei SVD:

$$A_{clean} = \sum_{i=1}^k \sigma_i u_i v_i^T \quad (10)$$

Pentru izolarea semnalului util, se menține doar $k = 1$, păstrând exclusiv componenta asociată cu σ_1 .

5. Atacul DPA și Corelația Pearson (CPA)

Consumul ipotetic de putere pentru o operație AES S-Box este modelat folosind Greutatea Hamming (HW):

$$H_{i,c} = HW(\text{SBox}[P_i \oplus c]) \quad (11)$$

unde P_i este textul clar, iar $c \in \{0, \dots, 255\}$ este un candidat pentru cheie.

Corelația Pearson (ρ) dintre matricea filtrată (A_{clean}) și modelul ipotetic (H) la momentul t este:

$$\rho(c, t) = \frac{\sum_{i=1}^m (H_{i,c} - \overline{H_c})(A_{clean}[i, t] - \overline{A_{clean}[t]})}{\sqrt{\sum_{i=1}^m (H_{i,c} - \overline{H_c})^2 \sum_{i=1}^m (A_{clean}[i, t] - \overline{A_{clean}[t]})^2}} \quad (12)$$

Cheia corectă c^* maximizează valoarea absolută a corelației:

$$c^* = \arg \max_c \left(\max_t |\rho(c, t)| \right) \quad (13)$$